



COMPUTAÇÃO EM NUVEM

AULA 2



Prof. Maike Cristian Rebelo de Lima



CONVERSA INICIAL

Redes em nuvem

Nesta abordagem, vamos explorar como as redes de computadores são projetadas, implementadas e gerenciadas em ambientes de nuvem. Como deve ser do seu conhecimento, a computação em nuvem revolucionou a forma como as empresas e organizações consomem recursos de TI, oferecendo escalabilidade, flexibilidade e eficiência sem precedentes.

Iremos mergulhar no mundo da computação em nuvem e explorar como as redes de computadores desempenham um papel fundamental nesse cenário. Vamos aprender sobre os conceitos básicos de redes de computadores e como eles se aplicam aos ambientes de nuvem, os diferentes modelos de serviço, as arquiteturas mais comuns e os principais serviços de rede e entrega de conteúdo oferecidos pelos principais provedores de nuvem, como a Amazon Web Services (AWS), Microsoft Azure e Google Cloud Platform (GCP).

Ao final deste conteúdo, você terá uma compreensão sólida de como as redes de computadores funcionam em ambientes de nuvem e estará preparado para explorar e trabalhar com essas tecnologias em seus projetos futuros.

TEMA 1 – CONCEITOS BÁSICOS DE REDES DE COMPUTADORES

As redes de computadores formam a base da comunicação digital, permitindo que dispositivos interajam entre si, compartilhem recursos e troquem informações de maneira rápida e eficiente. Desde pequenas redes locais (LANs) em escritórios até a vasta interconexão global que é a internet, as redes são essenciais para praticamente todas as operações de TI modernas.

Os conceitos básicos de redes envolvem a compreensão de como os dispositivos são conectados, como os dados são transmitidos e como a comunicação é gerenciada e protegida. Isso inclui a familiarização com elementos fundamentais como protocolos de comunicação, endereçamento IP, sub-redes, roteadores, switches e firewalls. Esses componentes trabalham juntos para garantir que os dados sejam enviados e recebidos corretamente entre os dispositivos conectados, independentemente da distância ou da complexidade da rede.

Com a crescente dependência das organizações em sistemas digitais, o conhecimento sobre redes de computadores não só ajuda a manter a



infraestrutura operante, mas também é crucial para inovar e melhorar a eficiência das operações. Assim, dominar os conceitos básicos de redes é o primeiro passo para explorar o mundo das comunicações e da tecnologia da informação.

1.1 Introdução a redes

As redes de computadores são a espinha dorsal da comunicação moderna, permitindo a interconexão de dispositivos e a troca de informações de forma rápida e eficiente. Com o advento da computação em nuvem, as redes evoluíram para suportar não apenas a comunicação local, mas também a conectividade global por meio de infraestruturas distribuídas.

A computação em nuvem redefine o conceito tradicional de rede ao permitir que recursos de TI sejam acessados e gerenciados remotamente, oferecendo escalabilidade, flexibilidade e resiliência. Ao contrário das redes convencionais, que dependem de hardware físico no local, as redes em nuvem são altamente virtualizadas, utilizando datacenters distribuídos ao redor do mundo. Isso permite que as empresas se adaptem rapidamente às mudanças nas demandas de mercado, escalando seus serviços conforme necessário.

Entender os fundamentos das redes em nuvem é essencial para aproveitar ao máximo as suas capacidades, garantindo que a comunicação entre dispositivos, aplicativos e usuários seja segura, rápida e eficiente, independentemente da localização física.

1.1.1 Definição e importância das redes em nuvem

As redes em nuvem referem-se à interconexão de recursos e serviços de computação por meio da internet, permitindo que dados e aplicações sejam acessados e gerenciados remotamente em uma infraestrutura altamente escalável e flexível. Em vez de depender exclusivamente de servidores físicos e redes locais, as redes em nuvem utilizam datacenters distribuídos globalmente, gerenciados por provedores de serviços em nuvem como Amazon Web Services (AWS), Microsoft Azure, e Google Cloud Platform (GCP).

Definição:

Uma rede em nuvem é essencialmente uma rede virtual que interliga diferentes recursos de TI, como servidores, armazenamento e serviços de aplicação, por meio de uma infraestrutura de nuvem pública, privada ou híbrida.



Esses recursos são acessados via internet ou redes privadas, permitindo o gerenciamento centralizado, a escalabilidade automática e a flexibilidade no uso de recursos.

Importância:

A importância das redes em nuvem reside na sua capacidade de transformar a forma como as organizações gerenciam e expandem suas operações. Com as redes em nuvem, empresas podem rapidamente provisionar recursos, escalar serviços conforme a demanda e implementar soluções de recuperação de desastres com maior eficiência e menor custo. Além disso, as redes em nuvem oferecem maior resiliência e disponibilidade, já que os dados e serviços podem ser distribuídos geograficamente para garantir que falhas em um único local não afetem a continuidade do negócio.

Outro aspecto crucial das redes em nuvem é a sua capacidade de suportar inovações tecnológicas, como a Internet das Coisas (IoT), Inteligência Artificial (IA) e Big Data, que exigem uma infraestrutura de rede robusta e flexível. Com a nuvem, as organizações têm acesso a essas tecnologias avançadas sem a necessidade de grandes investimentos em infraestrutura física.

Em resumo, as redes em nuvem não são apenas uma tendência tecnológica, mas uma necessidade estratégica para organizações que buscam agilidade, escalabilidade e eficiência em um ambiente de negócios cada vez mais dinâmico e competitivo.

1.1.2 Comparação entre redes tradicionais e redes em nuvem

As redes tradicionais e as redes em nuvem diferem em vários aspectos, desde a arquitetura subjacente até a forma como os recursos são gerenciados e acessados. Compreender essas diferenças é essencial para decidir qual abordagem é mais adequada para as necessidades de uma organização.

Arquitetura

Redes tradicionais

Em uma rede tradicional, os recursos de TI, como servidores, armazenamento e redes, são implementados e gerenciados localmente. A infraestrutura física é propriedade da organização e geralmente está localizada em um datacenter on-premises (no local).



A configuração e a manutenção são responsabilidade da equipe de TI interna, o que pode exigir investimentos significativos em hardware, software e mão de obra especializada.

Redes em nuvem

As redes em nuvem utilizam a infraestrutura virtualizada fornecida por provedores de serviços em nuvem como AWS, Azure ou Google Cloud. Essa infraestrutura é distribuída globalmente e gerenciada remotamente, o que permite um escalonamento rápido e flexível de recursos conforme necessário.

A arquitetura em nuvem é baseada em recursos compartilhados e multitenancy, na qual múltiplos clientes compartilham a mesma infraestrutura física, mas com isolamento lógico garantido.

Escalabilidade

Redes tradicionais

Escalar uma rede tradicional pode ser complexo e dispendioso, exigindo a aquisição e instalação de novos equipamentos, além de possíveis interrupções durante o processo de expansão.

A capacidade de escalabilidade é limitada pela infraestrutura física existente e pelo espaço disponível no datacenter.

Redes em nuvem

A escalabilidade é uma das principais vantagens das redes em nuvem. Recursos podem ser aumentados ou reduzidos sob demanda, muitas vezes automaticamente, sem a necessidade de intervenção manual.

A capacidade de escalonamento é praticamente ilimitada, com a nuvem oferecendo recursos elásticos que podem crescer ou encolher conforme a demanda.

Custo

Redes tradicionais

O custo inicial para configurar uma rede tradicional é elevado, envolvendo a compra de hardware, licenças de software e a implementação de infraestrutura física.

Os custos operacionais incluem a manutenção contínua, atualizações e o consumo de energia, que podem se acumular ao longo do tempo.

Redes em nuvem

Em uma rede em nuvem, os custos iniciais são geralmente mais baixos, já que não há necessidade de grandes investimentos em infraestrutura física.



Em vez disso, os custos são distribuídos ao longo do tempo, com um modelo de pagamento baseado no uso ("*pay-as-you-go*").

Isso permite que as empresas ajustem seus custos de acordo com suas necessidades reais, evitando o excesso de provisionamento de recursos.

Segurança

Redes tradicionais

A segurança em redes tradicionais é gerenciada internamente, com a organização tendo controle total sobre as medidas de segurança, como firewalls, sistemas de detecção de intrusão e políticas de acesso.

Embora isso permita uma customização completa, também exige uma equipe de segurança altamente qualificada para manter a proteção contra ameaças.

Redes em nuvem

As redes em nuvem adotam um modelo de segurança compartilhada, em que o provedor de nuvem é responsável por proteger a infraestrutura subjacente, enquanto o cliente é responsável pela segurança de seus dados e aplicações na nuvem.

Provedores de nuvem geralmente oferecem ferramentas avançadas de segurança, como criptografia de dados, firewalls gerenciados e monitoramento contínuo de ameaças, que podem ser mais sofisticadas do que as soluções disponíveis para muitas organizações em ambientes tradicionais.

Flexibilidade e inovação

Redes tradicionais

A flexibilidade é limitada em redes tradicionais, uma vez que mudanças na infraestrutura podem ser complexas e demoradas, exigindo planejamento e investimento significativo.

A capacidade de inovação pode ser restringida pela rigidez da infraestrutura existente e pela necessidade de atualizações físicas para suportar novas tecnologias.

Redes em nuvem

Redes em nuvem são altamente flexíveis, permitindo que as organizações implementem novas tecnologias rapidamente e sem grandes mudanças na infraestrutura subjacente.



A nuvem facilita a experimentação e a inovação, com acesso a um vasto conjunto de serviços e ferramentas que podem ser implementados com apenas alguns cliques.

Em resumo, enquanto as redes tradicionais oferecem controle e segurança sob medida, as redes em nuvem destacam-se pela flexibilidade, escalabilidade e eficiência de custos. A escolha entre uma rede tradicional e uma rede em nuvem dependerá das necessidades específicas da organização, como requisitos de segurança, capacidade de escalonamento e considerações de custo. Em muitos casos, uma abordagem híbrida, que combina o melhor dos dois mundos, pode ser a solução ideal.

1.2 Infraestrutura de rede em nuvem

A infraestrutura de rede em nuvem é composta por uma série de componentes e serviços que permitem a interconexão de recursos computacionais distribuídos globalmente, garantindo a comunicação eficiente e segura entre dispositivos, aplicativos e usuários. Essa infraestrutura é projetada para ser escalável, flexível e altamente disponível, aproveitando as vantagens da virtualização e da distribuição geográfica.

1.2.1 Componentes principais da infraestrutura de rede em nuvem

Os principais componentes da infraestrutura de rede em nuvem incluem:

Web Clients:

São os dispositivos (como computadores, smartphones, tablets) que acessam os serviços de nuvem por meio da internet. Eles interagem com a infraestrutura de rede em nuvem utilizando protocolos como HTTP/HTTPS, permitindo o acesso a aplicações e dados armazenados remotamente.

Cloud Load Balancer:

O balanceador de carga na nuvem distribui o tráfego de rede entre múltiplos servidores ou instâncias de aplicação, garantindo alta disponibilidade e desempenho. Ele equilibra a carga de trabalho para evitar sobrecarga em um único recurso, melhorando a resiliência e a escalabilidade dos serviços.

Cloud DNS (Domain Name System):

O DNS na nuvem é responsável pela tradução de nomes de domínio em endereços IP, permitindo que os clientes acessem recursos na nuvem de forma



transparente. Serviços de DNS em nuvem geralmente incluem funcionalidades avançadas, como roteamento geográfico e failover automático, para melhorar a disponibilidade global.

Virtual Private Cloud (VPC):

A VPC é uma rede virtual privada que fornece controle total sobre o ambiente de rede na nuvem, incluindo endereçamento IP, sub-redes, roteamento e regras de firewall. Ela permite que as organizações isolem seus recursos na nuvem, configurando uma arquitetura de rede segura e segmentada.

VPN (Virtual Private Network):

A VPN permite a conexão segura entre a infraestrutura de rede on-premises e a nuvem, ou entre diferentes redes na nuvem. Utilizando criptografia, a VPN protege os dados em trânsito, garantindo que a comunicação entre diferentes partes da infraestrutura seja segura e confidencial.

A infraestrutura de rede em nuvem é projetada para ser distribuída globalmente, com datacenters localizados em várias regiões e zonas de disponibilidade. Isso permite que os serviços sejam oferecidos mais próximos aos usuários finais, reduzindo a latência e melhorando a experiência do usuário.

Regiões e Zonas de Disponibilidade:

As regiões são locais geográficos que contêm múltiplos datacenters, chamados zonas de disponibilidade. As zonas são configuradas para operar de forma independente, permitindo a alta disponibilidade e recuperação de desastres. As empresas podem distribuir suas aplicações e dados entre diferentes zonas para garantir resiliência e minimizar o risco de falhas catastróficas.

Escalabilidade Automática:

A infraestrutura de rede em nuvem suporta escalabilidade automática, ajustando dinamicamente os recursos computacionais e de rede em resposta à demanda. Isso é essencial para lidar com picos de tráfego, garantindo que os serviços permaneçam acessíveis e responsivos, independentemente da carga de trabalho.

1.2.2 WAN, LAN e internet

LAN (Rede de Área Local)

A LAN, ou Rede de Área Local, é um tipo de rede que conecta computadores e dispositivos dentro de uma área geográfica limitada, como uma



casa, escritório ou campus. Essas redes são caracterizadas por suas altas velocidades de transmissão de dados e pela proximidade física dos dispositivos conectados. Na LAN, os dispositivos, como computadores, impressoras e servidores, são geralmente interconectados por meio de cabos Ethernet ou redes sem fio (Wi-Fi), utilizando um switch ou roteador central para gerenciar o tráfego de dados. A LAN é usada principalmente para compartilhar recursos, como arquivos e impressoras, e para permitir a comunicação interna rápida e eficiente dentro de uma organização.

Características principais:

- Área de cobertura: restrita a um prédio ou campus;
- Velocidade de dados: geralmente alta (100 Mbps a 10 Gbps);
- Tecnologia de conexão: ethernet, wi-fi;
- Aplicação: comunicação interna, compartilhamento de recursos.

WAN (Rede de Área Ampla)


A WAN, ou Rede de Área Ampla, expande o conceito de rede para uma área geográfica muito maior, conectando múltiplas LANs que podem estar situadas em diferentes cidades, estados ou até mesmo países. A WAN permite que as redes locais se comuniquem e compartilhem recursos de forma remota, sendo essencial para empresas que operam em vários locais. A WAN utiliza tecnologias como MPLS, VPN ou SD-WAN para garantir a conectividade e a segurança dos dados em trânsito. Por sua natureza, a WAN tende a ter velocidades de transmissão de dados mais baixas em comparação com a LAN, devido à maior distância entre os pontos de conexão.

Características principais:

- Área de cobertura: pode abranger cidades, estados, países ou continentes;
- Velocidade de dados: variável, geralmente mais baixa que a LAN;
- Tecnologia de conexão: MPLS, VPN, SD-WAN;
- Aplicação: conexão entre filiais, acesso remoto, comunicação entre regiões distantes.

Internet

A internet é uma vasta rede global que conecta milhões de redes privadas, públicas, empresariais, acadêmicas e governamentais. A internet funciona como uma rede de redes, permitindo a interconexão global por meio de uma





Cobertura geográfica: a LAN cobre uma área local, a WAN abrange distâncias maiores conectando múltiplas LANs, e a internet conecta várias WANs em uma rede global;

Velocidade: a LAN oferece as maiores velocidades devido à proximidade dos dispositivos, enquanto a WAN pode ser mais lenta por cobrir distâncias maiores. A internet tem velocidades variadas dependendo da conexão;

Propriedade e controle: a LAN é geralmente gerida internamente por uma organização, a WAN pode ser gerida por provedores de serviços ou pela própria organização, enquanto a internet é uma rede pública e descentralizada;

Complexidade: a LAN é mais simples de configurar e gerenciar, enquanto a WAN e a internet envolvem tecnologias e protocolos mais complexos para garantir a conectividade e a segurança.

1.2.3 Distribuição e escalabilidade

A infraestrutura de rede em nuvem é projetada para ser distribuída globalmente, com datacenters localizados em várias regiões e zonas de disponibilidade. Isso permite que os serviços sejam oferecidos mais próximos aos usuários finais, reduzindo a latência e melhorando a experiência do usuário.

Regiões e zonas de disponibilidade:

As regiões são locais geográficos que contêm múltiplos datacenters, chamados zonas de disponibilidade. As zonas são configuradas para operar de forma independente, permitindo a alta disponibilidade e recuperação de desastres. As empresas podem distribuir suas aplicações e dados entre diferentes zonas para garantir resiliência e minimizar o risco de falhas catastróficas.

Escalabilidade automática:

A infraestrutura de rede em nuvem suporta escalabilidade automática, ajustando dinamicamente os recursos computacionais e de rede em resposta à demanda. Isso é essencial para lidar com picos de tráfego, garantindo que os serviços permaneçam acessíveis e responsivos, independentemente da carga de trabalho.

1.2.4 Segurança e gerenciamento

A segurança na infraestrutura de rede em nuvem é fundamental, com uma



abordagem que combina a responsabilidade compartilhada entre o provedor de nuvem e o cliente.

Firewalls e regras de segurança:

A nuvem permite a configuração de firewalls virtuais que controlam o tráfego de entrada e saída nas instâncias e sub-redes. Os administradores podem definir regras de segurança precisas para proteger os recursos contra acessos não autorizados e ameaças cibernéticas.

Monitoração e *logging*:

Serviços de monitoração e *logging* em nuvem fornecem visibilidade sobre o desempenho da rede, detecção de anomalias e auditoria de eventos de segurança. Isso ajuda as organizações a manter um ambiente de rede seguro e eficiente, com alertas em tempo real para possíveis problemas.

1.2.5 Conectividade e interoperabilidade

A infraestrutura de rede em nuvem facilita a conectividade entre diferentes ambientes e serviços, permitindo uma integração fluida entre redes on-premises, híbridas e múltiplas nuvens.

***Peering* e interconexões:**

As redes em nuvem podem ser interconectadas por meio de *peering* (conexão direta entre redes diferentes) ou por meio de interconexões dedicadas oferecidas pelos provedores de nuvem. Isso permite uma transferência de dados rápida e eficiente entre diferentes partes da infraestrutura.

APIs e integrações:

A infraestrutura de rede em nuvem é altamente programável, com APIs que permitem a automação de tarefas de gerenciamento, configuração e monitoramento. Essas APIs facilitam a integração com outras ferramentas e plataformas, permitindo a criação de ambientes de rede altamente personalizados e otimizados.

TEMA 2 – NOÇÕES DE ENDEREÇAMENTO E SUB-REDES

O endereçamento e a criação de sub-redes são conceitos fundamentais no mundo das redes de computadores, pois definem como os dispositivos se identificam e se comunicam em uma rede. Cada dispositivo conectado a uma rede precisa de um endereço IP (*Internet Protocol*) exclusivo para enviar e



receber dados, de maneira semelhante ao funcionamento dos endereços físicos no mundo real, que identificam casas ou empresas.

O protocolo IP é a base do endereçamento em redes, permitindo que os dados sejam roteados corretamente de um dispositivo a outro, independentemente da sua localização geográfica. Existem duas versões principais de IP em uso hoje: IPv4 e IPv6. O IPv4, com seus endereços de 32 bits, foi a primeira versão amplamente implementada e ainda é a mais comum. No entanto, com a crescente demanda por endereços IP, o IPv6, que utiliza endereços de 128 bits, foi introduzido para garantir a disponibilidade de endereços para todos os dispositivos conectados à internet.

Além do endereçamento IP, o conceito de sub-redes (*subnetting*) desempenha um papel crucial na organização e eficiência das redes. A criação de sub-redes permite que uma rede maior seja dividida em várias redes menores, facilitando a gestão, melhorando a segurança e otimizando o uso dos endereços IP. As sub-redes são definidas por meio de uma máscara de sub-rede, que determina qual parte do endereço IP é usada para identificar a rede e qual parte é usada para identificar os dispositivos dentro dessa rede.

2.1 Endereçamento IP

O endereçamento IP (*Internet Protocol*) é um dos pilares fundamentais das redes de computadores, servindo como a base para a comunicação entre dispositivos conectados. Cada dispositivo em uma rede, seja um computador, smartphone, servidor ou outro equipamento, precisa de um endereço IP único para enviar e receber dados. Esse endereço IP funciona de maneira semelhante a um endereço residencial, permitindo que as informações cheguem ao destino correto.

2.1.1 IPv4

O IPv4 (*Internet Protocol Version 4*) é a quarta versão do protocolo de internet e a mais amplamente utilizada para identificar dispositivos em uma rede. Apesar de sua ampla adoção, o espaço de endereçamento do IPv4 é limitado e, com o crescimento exponencial da internet, os endereços IPv4 estão se tornando escassos. Isso levou ao desenvolvimento do IPv6, que oferece um espaço de endereçamento muito maior. No entanto, o IPv4 ainda é amplamente utilizado devido à sua compatibilidade com a infraestrutura existente e à sua simplicidade.




O IPv4 é essencial para a conectividade e o funcionamento das redes de computadores, facilitando a comunicação entre dispositivos em redes locais (LANs), redes de longa distância (WANs) e a internet como um todo. Utiliza endereços de 32 bits, permitindo aproximadamente 4,3 bilhões de endereços únicos. Com o crescimento exponencial de dispositivos conectados, essa quantidade se tornou insuficiente, levando à necessidade de reutilização de endereços e ao uso de NAT (*Network Address Translation*). A Figura 2 representa o datagrama do IPv4:

Figura 2 - Representação do Datagrama IPv4



Na representação da Figura 3, temos o cabeçalho IPv4:

Figura 3 - Representação do Cabeçalho IPv4





Estrutura de endereços IPv4

A estrutura de um endereço IPv4 é composta por 32 bits, divididos em quatro octetos (ou bytes) de 8 bits cada, totalizando 4 bytes. Cada octeto é representado como um número decimal separado por pontos, resultando no formato familiar, por exemplo, 192.168.1.1. Cada octeto pode ter um valor entre 0 e 255, o que dá ao IPv4 a capacidade de gerar cerca de 4,3 bilhões de endereços únicos.

Exemplo de estrutura de endereço IPv4:

- Formato decimal: 192.168.0.1
- Formato binário: 11000000.10101000.00000000.00000001

Nesta estrutura, os bits mais significativos (à esquerda) podem ser usados para identificar a rede, enquanto os bits menos significativos (à direita) identificam o *host* (dispositivo) dentro dessa rede. A divisão exata entre a parte da rede e a parte do *host* é determinada pela máscara de sub-rede, que desempenha um papel crucial no processo de roteamento de dados na rede.

Classificação e sub-redes

Os endereços IPv4 são tradicionalmente classificados em cinco classes principais, de A a E, com base no valor dos bits iniciais do endereço. Essa classificação ajuda a determinar quantas redes e quantos hosts podem ser suportados em cada classe:

Classe A:

- Primeiro Octeto: 1 a 126
- Formato: 0NNNNNNN.HHHHHHHH.HHHHHHHH.HHHHHHHH
- Uso: grandes redes com um número muito elevado de hosts (até 16 milhões de hosts por rede).

Classe B:

- Primeiro Octeto: 128 a 191
- Formato: 10NNNNNNN.NNNNNNNN.HHHHHHHH.HHHHHHHH
- Uso: redes médias, com até 65.534 hosts por rede.

Classe C:

- Primeiro Octeto: 192 a 223
- Formato: 110NNNNN.NNNNNNNN.NNNNNNNN.HHHHHHHH



- Uso: pequenas redes, com até 254 hosts por rede.

Classe D:

- Primeiro Octeto: 224 a 239
- Uso: multicast, não destinado a endereçamento de hosts específicos.

Classe E:

- Primeiro Octeto: 240 a 255
- Uso: reservado para fins experimentais.

Sub-redes (*Subnetting*)

O conceito de sub-redes permite que uma única rede IPv4 seja subdividida em várias redes menores, chamadas sub-redes. Isso é feito modificando a máscara de sub-rede, que define a parte do endereço IP que corresponde à rede e a parte que corresponde aos *hosts* dentro dessa rede. A máscara de sub-rede é representada no mesmo formato de quatro octetos que um endereço IP, e usa bits "1" para identificar a parte de rede e bits "0" para a parte de *host*.

Exemplo de sub-rede:

- Endereço IP: 192.168.1.0
- Máscara de Sub-rede: 255.255.255.0
 - Formato Binário: 11111111.11111111.11111111.00000000
- Rede: 192.168.1.0
- Hosts: 192.168.1.1 a 192.168.1.254

Neste exemplo, a máscara de sub-rede 255.255.255.0 indica que os primeiros três octetos (192.168.1) identificam a rede, e o último octeto (0) pode ser usado para identificar até 254 hosts únicos dentro dessa rede.

2.1.2 IPv6

Introduz endereços de 128 bits, oferecendo um espaço de endereçamento praticamente ilimitado (aproximadamente 3.4×10^{38} endereços). Essa abundância elimina a necessidade de NAT, simplifica a configuração de rede e suporta um número muito maior de dispositivos, crucial para o crescimento da Internet das Coisas (IoT), oferecendo a infraestrutura necessária para conectar bilhões de novos dispositivos ao redor do mundo. Embora a



transição completa do IPv4 para o IPv6 ainda esteja em andamento, o IPv6 já é suportado pela maioria dos sistemas operacionais modernos e infraestruturas de rede, preparando o terreno para a próxima geração da conectividade global.

Os endereços IPv6 são representados em formato hexadecimal e são compostos por oito grupos de quatro dígitos, separados por dois pontos, como 2001:0db8:85a3:0000:0000:8a2e:0370:7334. Esse formato, além de suportar uma quantidade muito maior de dispositivos, também inclui recursos avançados, como autoconfiguração de endereços, maior segurança integrada e suporte aprimorado para mobilidade.

Estrutura de endereços IPv6

O endereço IPv6 é composto por 128 bits, o que permite um número quase infinito de endereços, garantindo a escalabilidade necessária para o crescimento contínuo da internet. A estrutura do endereço IPv6 é significativamente diferente da do IPv4, tanto em termos de comprimento quanto de representação.

Formato do endereço IPv6

Um endereço IPv6 é representado em formato hexadecimal, dividido em oito grupos de quatro dígitos, separados por dois pontos. Cada grupo de quatro dígitos hexadecimais representa 16 bits, totalizando os 128 bits do endereço completo.

Exemplo de endereço IPv6:

- 2001:0db8:85a3:0000:0000:8a2e:0370:7334

Neste exemplo:

- Cada grupo separado por dois pontos (:) é um bloco de 16 bits.
- Zeros à esquerda em cada bloco podem ser omitidos para simplificar a representação.
- Sequências contínuas de blocos 0000 podem ser reduzidas a :: uma vez em um endereço, simplificando ainda mais a leitura e escrita.

Partes de um endereço IPv6

O endereço IPv6 é geralmente dividido em duas partes principais:

- **Prefixo da rede:** os primeiros 64 bits (quatro primeiros blocos) identificam a rede a que o endereço pertence, semelhante ao conceito de sub-rede no IPv4.



- **Identificador de Interface (ID de Interface):** os últimos 64 bits (quatro últimos blocos) identificam a interface específica de um dispositivo na rede. Esse identificador é geralmente derivado do endereço MAC do dispositivo, mas pode ser gerado aleatoriamente para melhorar a privacidade.

Exemplo de divisão:

- Prefixo da rede: 2001:0db8:85a3
- ID de interface: 0000:0000:8a2e:0370:7334

Simplificação e notação abreviada

O IPv6 permite simplificações para facilitar o uso:

- **Omissão de zeros à esquerda:** zeros à esquerda em cada bloco de 16 bits podem ser omitidos. Por exemplo, 0db8 pode ser escrito como db8.
- **Compressão de blocos de zeros:** blocos consecutivos de 0000 podem ser representados como ::, mas essa compressão só pode ser usada uma vez em um endereço.

Exemplo de compressão:

- Endereço Original: 2001:0db8:0000:0000:0000:8a2e:0370:7334
- Endereço Simplificado: 2001:db8::8a2e:370:7334

Tipos de endereços IPv6

Os endereços IPv6 podem ser categorizados em diferentes tipos com base em sua função:

- **Unicast:** um endereço que identifica uma única interface. O tráfego enviado para um endereço unicast vai para o dispositivo único que possui aquele endereço.
- **Multicast:** um endereço que identifica um grupo de interfaces. O tráfego enviado para um endereço multicast é entregue a todas as interfaces no grupo.
- **Anycast:** um endereço atribuído a múltiplas interfaces, geralmente em locais diferentes. O tráfego é roteado para a interface mais próxima com aquele endereço.

Benefícios e desafios da adoção do IPv6

- Melhor desempenho;



- Maior segurança;
- Maior escalabilidade;
- Facilita a gestão de grandes infraestruturas;
- Melhora a eficiência da rede.

2.2 IPs Públicos vs. Privados

Diferenças e aplicações práticas

Os endereços IP são classificados em públicos e privados, cada um com diferentes funções e aplicações dentro de uma rede.

IPs Públicos:

Definição: um IP público é um endereço que pode ser acessado diretamente pela internet. Ele é único em todo o mundo e é atribuído a dispositivos ou servidores que precisam ser acessados externamente, como sites, servidores de e-mail ou qualquer serviço hospedado que precise de conectividade global.

Aplicações práticas: IPs públicos são usados para identificar e localizar dispositivos na internet. Por exemplo, um site hospedado em um servidor web precisará de um IP público para que usuários da internet possam acessá-lo. Empresas que oferecem serviços acessíveis pela internet, como servidores de banco de dados, também utilizam IPs públicos.

Exemplo: um endereço IP público pode ser algo como 203.0.113.1.

IPs Privados:

Definição: um IP privado é um endereço usado dentro de uma rede local (LAN) e não pode ser acessado diretamente pela internet. Esses endereços são reutilizados em diferentes redes, pois não há necessidade de serem únicos globalmente. IPs privados são designados para dispositivos dentro de uma rede doméstica ou corporativa, como computadores, impressoras e servidores internos.

Aplicações práticas: IPs privados são usados para comunicação interna dentro de uma organização ou rede doméstica. Por exemplo, um roteador doméstico pode atribuir IPs privados aos dispositivos conectados a ele, como 192.168.0.1 para o roteador e 192.168.0.2 para um computador. Os dispositivos com IPs privados se comunicam entre si, mas acessam a internet por meio de um IP público compartilhado via NAT (Network Address Translation).



Exemplo: intervalos de IPs privados comuns incluem 192.168.0.0/16, 10.0.0.0/8, e 172.16.0.0/12.

Segurança e gestão de IPs na nuvem

Na nuvem, a distinção entre IPs públicos e privados é essencial para configurar uma infraestrutura segura e eficiente.

Segurança:

Isolamento: IPs privados são fundamentais para isolar a infraestrutura interna na nuvem, protegendo servidores e outros recursos que não precisam de acesso direto à internet. Ao limitar o uso de IPs públicos, uma organização pode reduzir a superfície de ataque, minimizando a exposição a ameaças externas.

Firewalls e regras de segurança: na nuvem, os IPs públicos são frequentemente protegidos por firewalls que filtram o tráfego de entrada e saída, permitindo apenas conexões autorizadas. IPs privados, por outro lado, são usados em conjunto com regras de segurança que controlam o tráfego interno, garantindo que apenas dispositivos e serviços autorizados possam se comunicar entre si.

Gestão de IPs na nuvem:

Atribuição dinâmica: na maioria dos provedores de nuvem, os IPs públicos são frequentemente atribuídos de forma dinâmica e podem mudar cada vez que uma instância é reiniciada. Isso é gerenciado automaticamente pelo provedor de nuvem, mas IPs estáticos (ou elásticos) também podem ser solicitados para aplicações que exigem um endereço IP fixo.

Sub-redes e VPCs: as Virtual Private Clouds (VPCs) permitem a criação de sub-redes privadas na nuvem, nas quais os dispositivos podem operar exclusivamente com IPs privados. Apenas recursos específicos que precisam de acesso externo são configurados para usar IPs públicos, muitas vezes com uma camada adicional de segurança, como NAT gateways, para controlar o tráfego.

TEMA 3 – NUVENS PRIVADAS VIRTUAIS (VPC)


3.1 Estrutura de VPC

Virtual Private Clouds (VPC) ou Nuvens Privadas Virtuais, são isolamentos lógicos que são provisionadas nos *Data Centers* do *Cloud Providers*, de uma maneira que o usuário tenha que se preocupar apenas com



a configuração dentro da console, sem precisar realizar efetivamente o provisionamento dos recursos de rede. Uma VPC provê a comunicação entre os serviços de uma maneira interna, ou seja, cada recurso que está no contexto de uma VPC A, só irá se comunicar com os recursos que estão contidos na VPC A ou que tenham acesso via *Peering* a essa VPC. Para realização de comunicação com a internet existem mecanismos como o NAT ou o uso de IPs públicos, porém esse último não é muito indicado por ser uma superfície explorável em ataques. Para ilustrar de uma maneira didática os conceitos envolvidos, temos a Figura 4:

Figura 4 - Ilustração de isolamento entre ambientes DEV, QA e PROD



Crédito: Maíke Cristian Rebelo de Lima/Chat GPT/AI.



3.1.1 Regiões e zonas de disponibilidade

As zonas de disponibilidade e as regiões que são adotadas nos *Cloud Providers* são de fundamental importância para questões de redundância dentro do contexto de Computação em Nuvem. Imaginemos um caso hipotético, em que existe uma aplicação de *e-commerce* na qual temos vários acessos por dia, porém teremos uma campanha em uma data específica. Em caso de falha dessa aplicação, caso ela estivesse apenas em um *Data Center*, o impacto comercial seria imenso, uma vez que a aplicação ficaria indisponível. Dentro desse contexto, existe em Computação em Nuvem, o conceito de Zonas e Regiões, no qual podemos ter um *cluster* criado em *Multi-Region*, no qual podemos ter máquinas funcionando em Iowa e também em São Paulo.

Definições e impacto na resiliência da rede

Regiões

Regiões são localizações geográficas distintas onde os provedores de serviços de nuvem (como Amazon Web Services, Microsoft Azure e Google Cloud Platform) mantêm seus datacenters. Cada região é projetada para ser completamente independente e isolada das demais, proporcionando aos usuários a capacidade de implantar recursos próximos aos seus clientes ou conforme requisitos regulatórios e de conformidade.

Características das regiões:

- **Isolamento geográfico:** as regiões estão localizadas em diferentes partes do mundo, permitindo que as organizações escolham onde hospedar seus dados e aplicações com base na proximidade aos usuários finais, latência desejada e requisitos legais;
- **Independência:** cada região opera de forma autônoma, com infraestrutura e serviços separados, minimizando o risco de falhas sistêmicas que afetem múltiplas regiões simultaneamente;
- **Conformidade e regulamentação:** hospedar dados em regiões específicas ajuda as empresas a cumprirem leis e regulamentações locais relacionadas à privacidade e segurança de dados.

Zonas de disponibilidade

Zonas de Disponibilidade (também conhecidas como AZs) são subdivisões dentro de uma região. Cada zona consiste em um ou mais *Data*



Centers fisicamente separados e isolados uns dos outros, mas interconectados por redes de alta velocidade e baixa latência.

Características das Zonas de Disponibilidade:

- **Isolamento físico:** as AZs estão localizadas em diferentes instalações físicas, muitas vezes separadas por vários quilômetros, para proteger contra falhas locais, como incêndios, inundações ou interrupções de energia;
- **Interconectividade:** apesar do isolamento, as AZs dentro de uma região são conectadas por redes rápidas e redundantes, permitindo a sincronização eficiente de dados e a distribuição de carga entre elas;
- **Alta disponibilidade:** implantar recursos por meio de múltiplas AZs aumenta significativamente a disponibilidade e a resiliência das aplicações, permitindo que elas continuem operando mesmo se uma AZ enfrentar problemas.

3.1.2 Regras de firewall e rotas

As regras de firewall são essenciais para o controle de segurança em uma rede, pois determinam quais tipos de tráfego são permitidos ou bloqueados ao entrar ou sair de uma rede ou sub-rede. Essas regras são configuradas para garantir que apenas o tráfego autorizado possa acessar os recursos internos e que os dispositivos dentro da rede possam se comunicar com o mundo externo de forma controlada e segura.

Regras de firewall

As regras de firewall são criadas para definir o que pode entrar e sair de uma rede, baseando-se em critérios como endereço IP, protocolo, porta e origem ou destino do tráfego. Em uma VPC (*Virtual Private Cloud*), essas regras são aplicadas tanto em grupos de segurança quanto em listas de controle de acesso à rede (Network ACLs), e podem ser configuradas para diferentes camadas de segurança:

- **Grupos de segurança:** aplicados a instâncias específicas, controlam o tráfego de entrada e saída com base em regras definidas. Por exemplo, um grupo de segurança pode permitir tráfego HTTP e HTTPS de qualquer origem, mas restringir o acesso SSH apenas a endereços IP específicos;



- **Network ACLs (Listas de Controle de Acesso):** operam no nível da sub-rede, controlando o tráfego que entra ou sai de toda a sub-rede. As ACLs são mais amplas e podem aplicar regras adicionais para reforçar a segurança em múltiplas instâncias dentro da sub-rede.

Essas configurações são fundamentais para proteger os endpoints, garantindo que apenas o tráfego necessário, autorizado e seguro tenha acesso aos recursos internos, ao mesmo tempo em que minimizem a exposição a potenciais ameaças.

Rotas

As tabelas de rotas são usadas para definir o caminho que o tráfego deve seguir para alcançar diferentes destinos dentro de uma VPC ou na internet. Cada sub-rede em uma VPC possui uma tabela de rotas associadas que especifica como o tráfego deve ser encaminhado, seja para outras sub-redes dentro da VPC, seja para a internet por meio de um gateway apropriado.

Tabelas de rotas internas: controlam o tráfego dentro da VPC, permitindo a comunicação entre diferentes sub-redes. As rotas internas podem ser configuradas para isolar ou interligar sub-redes, dependendo das necessidades de segurança e arquitetura da rede.

Rotas externas: determinam como o tráfego é encaminhado para fora da VPC, geralmente por meio de um Internet Gateway (para tráfego público) ou um NAT Gateway (para permitir que instâncias em sub-redes privadas acessem a Internet de forma segura).

3.2 Conectividade entre VPCs

Conforme abordado no Tópico 3, as VPCs servem para isolar ambientes (Ambiente A, Ambiente B e Ambiente C) ou ter produtos diferentes em redes diferentes, visando maior isolamento dos produtos, seja um banco de dados de um micro serviço, que use um banco para escrita e um para leitura, precisamos ter em alguns casos interconectividade entre essas redes, isto é, por exemplo temos a rede de Ambiente A, em que está hospedado o Servidor A da Ferramenta que faz CI/CD de todo o nosso código. Dessa forma, iremos precisar que esse recurso consiga acessar os ambientes de Ambiente B e Ambiente C, pois toda a entrega de código e as automações envolvidas nesse processo



estarão nesse Servidor A. Como faremos essa interconectividade entre redes privadas? Será explicado nos exemplos a seguir.

3.2.1 VPC Peering

O VPC Peering é uma funcionalidade que permite a interconexão entre duas ou mais Virtual Private Clouds (VPCs), possibilitando que as instâncias de diferentes VPCs se comuniquem entre si como se estivessem na mesma rede. Esse tipo de conexão é altamente seguro e direto, utilizando a infraestrutura privada dos provedores de nuvem, sem a necessidade de passar pela internet pública.

Com o VPC Peering, as organizações podem facilitar a comunicação entre diferentes ambientes de rede que estejam separados em VPCs distintas, como ambientes de desenvolvimento, teste e produção, ou até mesmo entre VPCs de diferentes contas na nuvem. Um dos principais benefícios do VPC Peering é a baixa latência e a alta largura de banda, garantindo que o tráfego de rede seja eficiente e seguro.

Características do VPC Peering:

- **Conexão direta:** estabelece uma conexão direta entre VPCs, sem a necessidade de gateways adicionais, VPNs ou Internet;
- **Segurança:** todo o tráfego entre as VPCs conectadas via Peering é mantido dentro da rede privada do provedor de nuvem, aumentando a segurança;
- **Escalabilidade:** permite a expansão de redes na nuvem, conectando múltiplas VPCs à medida que a infraestrutura da empresa cresce;
- **Isolamento:** mantém o isolamento entre VPCs, oferecendo controle granular sobre o tráfego que pode ou não ser roteado entre elas.

Casos de uso:

- **Conectividade entre ambientes:** facilita a comunicação entre diferentes ambientes, como desenvolvimento, QA e produção, mantendo-os separados para controle e segurança, mas permitindo a transferência de dados quando necessário;
- **Compartilhamento de serviços:** conecta VPCs que compartilham serviços comuns, como bases de dados centralizadas, sem expô-los à Internet;



- Multicloud e multicontas: conecta VPCs que estão em diferentes contas ou até em diferentes regiões, suportando arquiteturas multicontas e multirregionais.

3.2.2 Shared VPC

A Shared VPC (VPC Compartilhada) é um recurso avançado que permite que múltiplos projetos ou contas na nuvem compartilhem uma única VPC, enquanto ainda mantém uma separação de responsabilidades e controle. Com uma VPC Compartilhada, recursos críticos, como sub-redes, gateways e instâncias de computação, podem ser centralizados em uma VPC principal, mas acessados por projetos ou contas individuais, cada uma com seus próprios direitos de acesso e políticas de segurança.

Esse modelo é particularmente útil em grandes organizações em que é necessário gerenciar e controlar centralmente os recursos de rede, mas ao mesmo tempo permitir que diferentes equipes ou departamentos operem de forma independente dentro da mesma infraestrutura de rede.

Características da Shared VPC:

- Centralização de recursos: permite que os recursos de rede, como sub-redes e gateways, sejam gerenciados de forma centralizada, facilitando a administração e a segurança;
- Isolamento e controle: embora compartilhem a mesma VPC, os projetos podem ser isolados uns dos outros, com controle granular sobre quem pode acessar o quê;
- Redução de complexidade: reduz a necessidade de configurar VPCs separadas para cada projeto, simplificando a arquitetura de rede e o gerenciamento;
- Escalabilidade: suporta muitos projetos e contas, permitindo o crescimento da infraestrutura sem complicações adicionais de rede.

Casos de uso:

- Ambientes corporativos: grandes empresas que precisam centralizar a gestão de rede, mas que possuem múltiplas equipes de desenvolvimento ou operações que precisam de acesso separado;



- Provedores de serviço: empresas que oferecem serviços em nuvem para várias divisões internas ou para clientes externos, permitindo que todos compartilhem a mesma infraestrutura de rede com a separação adequada;
- Projetos colaborativos: cenários onde múltiplos projetos precisam acessar os mesmos recursos de rede, como uma base de dados central ou uma infraestrutura de segurança comum.

TEMA 4 – NUVENS HÍBRIDAS

Com o advento das nuvens públicas, que são gerenciadas por grandes *players*, algumas instituições e empresas decidiram continuar com seus *Data Centers* próprios ou por regulamentação de leis ou por decisões negociais. Desta forma, para não estarem longe das facilidades e dos produtos inovadores e que facilitam em muitas etapas do desenvolvimento de software, surgiu o conceito de Nuvens Híbridas, que são a interconexão entre uma gama de servidores e/ou *Data Centers* dessas instituições e as nuvens públicas efetivamente.

Em linhas gerais, a adoção das nuvens híbridas combina elementos das nuvens privada e pública. Permite a flexibilidade de utilizar recursos próprios e de provedores de nuvem pública conforme a necessidade.

4.1 Conceito de nuvens híbridas

A nuvem híbrida é um modelo de infraestrutura de TI que combina a utilização de nuvens públicas e privadas, além de infraestrutura local (**on-premises**). Este modelo permite que as organizações tirem proveito dos benefícios dos diferentes tipos de nuvem, oferecendo flexibilidade, escalabilidade e maior controle sobre os recursos e dados.

Em uma arquitetura de nuvem híbrida, as empresas podem manter cargas de trabalho e dados sensíveis em uma nuvem privada ou infraestrutura local, enquanto utilizam a nuvem pública para outras necessidades, como computação adicional durante picos de demanda ou para acessar serviços avançados oferecidos pelos provedores de nuvem pública. A interconexão entre esses ambientes é feita de maneira a permitir a movimentação de dados e aplicações de forma segura e eficiente entre a nuvem privada e a nuvem pública.

Principais características da nuvem híbrida:



1. Flexibilidade:

- Permite a escolha do ambiente mais adequado para cada carga de trabalho, seja ele *on-premises*, em nuvem pública ou privada.

2. Escalabilidade:

- Possibilita a expansão rápida da capacidade computacional utilizando a nuvem pública, sem a necessidade de grandes investimentos em infraestrutura física.

3. Segurança e conformidade:

- Oferece controle sobre onde os dados são armazenados e como são gerenciados, facilitando o cumprimento de normas e regulamentos de segurança.

4. Custo-eficiência:

- Combina a utilização de recursos *on-premises* com a nuvem pública, otimizando os custos operacionais ao usar a nuvem pública apenas quando necessário.

5. Portabilidade de aplicações:

- Facilita a movimentação de aplicações entre diferentes ambientes de nuvem, permitindo que as empresas adotem uma estratégia de TI mais ágil e responsiva às suas necessidades.

4.2 Formas de conexão em nuvens híbridas

4.2.1 IPsec VPN

IPsec é um conjunto de protocolos para proteger comunicações IP por meio de autenticação e criptografia de cada pacote IP. Ele utiliza modos de transporte e túnel para proteger a comunicação ponto a ponto ou entre redes. Suas aplicações incluem VPNs e comunicações seguras entre redes. As vantagens são alta segurança e flexibilidade em proteger vários tipos de tráfego IP, enquanto as desvantagens incluem configuração complexa e impacto potencial no desempenho.

O IPsec pode ser usado para o seguinte:

- Fornecer segurança ao roteador quando ocorrer envio de dados pela Internet pública;
- Criptografar os dados da aplicação;



- Autenticar dados rapidamente, caso os dados se originem de um remetente conhecido;
- Proteger os dados da rede configurando circuitos criptografados, chamados de túneis IPsec, que criptografam todos os dados enviados entre dois endpoints.

As organizações usam o IPsec para se proteger contra ataques de reprodução. O ataque de reprodução, ou “ataque *man-in-the-middle*”, corresponde ao ato de interceptar e alterar uma transmissão em andamento, roteando dados para um computador intermediário. O protocolo IPsec atribui um número sequencial a cada pacote de dados e realiza verificações para detectar sinais de pacotes duplicados.

Quais são os modos de IPsec?

O IPsec opera em dois modos diferentes com variados graus de proteção.

Túnel

O modo de túnel IPsec é adequado para a transferência de dados em redes públicas, pois aumenta a proteção dos dados contra partes não autorizadas. O computador criptografa todos os dados, incluindo os dados e o cabeçalho, e anexa um novo cabeçalho a eles.

Transporte

O modo de transporte IPsec criptografa apenas os dados do pacote de dados, portanto, o cabeçalho IP é mantido em seu formato original. O cabeçalho do pacote que não foi criptografado permite que os roteadores identifiquem o endereço de destino de cada pacote de dados. Dessa forma, o transporte IPsec é usado em uma rede próxima e confiável, como a proteção de uma conexão direta entre dois computadores.

O que é VPN IPsec?

A VPN, ou rede privada virtual, é um software de rede que permite aos usuários navegar na internet de forma anônima e segura. Uma VPN IPsec corresponde a um software VPN que usa o protocolo IPsec para criar túneis criptografados na internet. Isso fornece encriptação de ponta a ponta, o que significa que os dados são codificados no computador e decodificados no servidor receptor.

VPN SSL

A sigla SSL significa “*secure socket layer*”. É um protocolo de segurança que protege o tráfego da Web. Uma VPN SSL corresponde a um serviço de segurança de rede baseado em navegadores que usa o protocolo SSL integrado para criptografar e proteger a comunicação de rede.

Qual é a diferença entre VPN IPSec e VPN SSL?


Ambos os protocolos de segurança funcionam em diferentes camadas do modelo de interconexão de sistemas abertos (OSI). O modelo OSI define a estrutura em camadas na qual os computadores trocam dados em uma rede.

Os protocolos IPSec se aplicam às camadas de rede e transporte no meio do modelo OSI. Enquanto isso, o SSL criptografa os dados na camada superior de aplicações. Você pode se conectar a uma VPN SSL usando um navegador Web, mas deve instalar um software separado para usar VPNs IPSec.

4.2.2 Direct Connect

Conexões Diretas entre os serviços de infraestrutura de uma determinada empresa e os serviços de um determinado provedor de Computação em Nuvem podem ser favoráveis em cenários de empresas que possuem leis que regulamentam o seu funcionamento e exigem que os dados fiquem em servidores físicos em *Data Centers* próprios (como por exemplo os sistemas bancários), são métodos de baixa latência que os provedores de nuvem disponibilizam em seus serviços de redes, visando atender essa demanda de clientes. Na Figura 5 podemos verificar como se comportam os serviços de *Direct Connect*, visando ilustrar as etapas acima descritas:

Figura 5 - Exemplo de Direct Peering em Cloud AWS





4.3 Vantagens e desvantagens das nuvens híbridas

Quadro 1 - Vantagens e desvantagens da utilização de nuvens híbridas

Aspectos	Vantagens	Desvantagens
Flexibilidade e Escalabilidade	Permite escalar conforme a demanda utilizando recursos on-premises e na nuvem.	
Otimização de Custos	Otimiza custos mantendo cargas previsíveis on-premises e variáveis na nuvem.	
Melhoria na Segurança e Conformidade	Maior controle sobre dados sensíveis e conformidade com regulamentações.	
Maior Resiliência e Recuperação de Desastres	Aumenta a resiliência com replicação de dados entre nuvem pública e privada.	
Suporte para Inovação e Desenvolvimento Ágil	Facilita testes rápidos e desenvolvimento ágil na nuvem pública.	
Complexidade de Gestão		Gestão mais complexa de múltiplos ambientes.
Custos Potenciais Ocultos		Possíveis custos elevados com integração e transferência de dados.
Desafios de Segurança e Conformidade		Dificuldade em manter políticas de segurança consistentes.
Dependência de Conectividade		Risco de impacto de desempenho devido a problemas de conectividade.
Integração e Interoperabilidade		Desafios de integração entre diferentes plataformas e tecnologias.

Fonte: Maike Cristian Rebelo de Lima.

TEMA 5 – BALANCEAMENTO DE CARGA

5.1 Introdução ao balanceamento de carga

O balanceamento de carga é uma técnica essencial em redes de computadores e sistemas de TI que visa distribuir o tráfego de rede ou as cargas de trabalho de maneira uniforme entre vários servidores ou recursos computacionais. O principal objetivo do balanceamento de carga é garantir que nenhum servidor ou recurso fique sobrecarregado, o que poderia causar degradação de desempenho ou até mesmo falhas no sistema.

Em um ambiente de TI moderno, em que a alta disponibilidade, o desempenho otimizado e a escalabilidade são cruciais, o balanceamento de carga desempenha um papel fundamental. Ele é amplamente utilizado em data



centers, infraestruturas de nuvem e redes corporativas para gerenciar o tráfego de usuários em aplicações web, serviços de backend e outras aplicações críticas.

Existem diferentes métodos e algoritmos de balanceamento de carga que podem ser aplicados, dependendo das necessidades específicas do sistema ou da aplicação. Esses métodos variam desde algoritmos simples, como Round Robin, até abordagens mais sofisticadas, como Least Connections e IP Hashing, que levam em consideração a carga atual dos servidores, a proximidade geográfica dos usuários ou outras métricas relevantes.

Principais benefícios do balanceamento de carga:

1. Alta disponibilidade:

- Ao distribuir as solicitações entre vários servidores, o balanceamento de carga ajuda a garantir que os serviços permaneçam disponíveis, mesmo se um ou mais servidores falharem.

2. Escalabilidade:

- Permite que novos servidores sejam adicionados ao *pool* de recursos facilmente, permitindo que o sistema escale horizontalmente à medida que a demanda cresce.

3. Melhor desempenho:

- Otimiza a utilização dos recursos, assegurando que as solicitações dos usuários sejam atendidas pelo servidor mais adequado, reduzindo o tempo de resposta e melhorando a experiência do usuário.

4. Redundância:

- Em conjunto com outras técnicas, como failover, o balanceamento de carga contribui para a redundância do sistema, aumentando a resiliência contra falhas.

5. Manutenção facilitada:

- Facilita a manutenção dos servidores, permitindo que um servidor seja retirado temporariamente para atualizações ou reparos sem interromper o serviço.




5.2 Tipos de balanceamento de carga

Podemos definir os principais tipos de balanceamento de carga como: HTTPS, SSL Proxy, e TCP Proxy. O tipo HTTPS é o mais amplamente utilizado, pois opera na camada mais alta do Modelo OSI, a Camada 7 (Aplicação), na qual as páginas da web e outros conteúdos são efetivamente renderizados para os usuários finais.

O SSL Proxy trabalha na Camada 6 (Apresentação), funcionando como uma ponte entre a Camada de Aplicação e a Camada de Transporte, realizando a criptografia e descriptografia dos dados antes que eles sejam transmitidos ou após serem recebidos. Isso permite que os dados sejam protegidos durante a transmissão, mas ainda acessíveis na Camada de Aplicação.

A Figura 6 representa como definir efetivamente como escolher qual a melhor estratégia de Balanceamento de Carga:

Figura 6 - Escolha de estratégia de balanceamento de carga



5.2.1 HTTP(S) e SSL Proxy

HTTP(S) Proxy e SSL Proxy são dois tipos de balanceadores de carga que operam em diferentes camadas do Modelo OSI, sendo amplamente utilizados para gerenciar o tráfego de aplicações web e garantir a segurança das comunicações.

HTTP(S) Proxy: este tipo de balanceador de carga funciona na Camada 7 (Aplicação) do Modelo OSI. Ele distribui o tráfego HTTP e HTTPS entre vários



servidores de backend, permitindo que as páginas da web sejam servidas de forma eficiente e segura. O HTTP(S) Proxy é capaz de inspecionar o conteúdo das requisições e respostas, o que possibilita a implementação de políticas baseadas em URL, cabeçalhos ou conteúdo específico da aplicação.

Aplicações:

- **Balanceamento de tráfego web:** distribui as requisições de usuários entre múltiplos servidores web para otimizar a performance e garantir alta disponibilidade;
- **Segurança:** pode ser utilizado para proteger aplicações web, implementando inspeção de tráfego, redirecionamento de URLs e outras políticas de segurança;
- **Otimização de conteúdo:** garante que os usuários recebam o conteúdo mais próximo de suas localizações, melhorando a experiência do usuário.

SSL Proxy: o SSL Proxy opera na Camada 6 (Apresentação) do Modelo OSI. Ele é responsável por terminar a conexão SSL/TLS do cliente, descriptografar o tráfego antes de encaminhá-lo aos servidores de backend ou criptografar as respostas antes de enviá-las de volta ao cliente. Isso reduz a carga de trabalho dos servidores de backend, que não precisam lidar com o processamento da criptografia.

Aplicações:

- **Descarregamento de SSL:** permite que a criptografia/descriptografia seja gerenciada pelo proxy, liberando os servidores de backend para focarem no processamento da aplicação;
- **Inspeção de tráfego criptografado:** facilita a inspeção de tráfego SSL/TLS para detecção de ameaças, implementação de políticas de segurança e otimização de tráfego;
- **Conformidade e segurança:** garante que as conexões SSL/TLS sejam gerenciadas centralmente, ajudando na conformidade com regulamentos de segurança.

5.2.2 TCP Proxy

O TCP Proxy é um balanceador de carga que opera na Camada 4 (Transporte) do Modelo OSI. Ele é responsável por encaminhar o tráfego TCP



entre o cliente e os servidores de backend sem inspecionar o conteúdo da carga útil das mensagens. Diferentemente dos proxies HTTP(S) e SSL, o TCP Proxy não se preocupa com o conteúdo das mensagens ou com as especificidades dos protocolos de aplicação, o que o torna ideal para aplicações que requerem alta performance e baixa latência.

Funcionamento:

- O TCP Proxy age como um intermediário entre o cliente e o servidor, estabelecendo duas conexões TCP: uma entre o cliente e o proxy, e outra entre o proxy e o servidor de backend. Ele encaminha os pacotes de dados conforme eles são recebidos, garantindo uma comunicação eficiente e transparente.

Cenários de Uso:

- Serviços de banco de dados: ideal para balancear o tráfego de bancos de dados que utilizam o protocolo TCP, como MySQL ou PostgreSQL;
- Aplicações em tempo real: utilizado em aplicações que requerem latência mínima, como jogos on-line e serviços de streaming, em que o conteúdo da mensagem não precisa ser inspecionado;
- Serviços de mensageria: utilizado em sistemas de mensagens que operam sobre TCP, no qual a entrega rápida e ordenada das mensagens é crucial.

5.2.3 Balanceamento Regional vs. Interno

O Balanceamento Regional e o Balanceamento Interno são estratégias de balanceamento de carga utilizadas para distribuir o tráfego de rede em diferentes contextos e com diferentes objetivos.

Balanceamento Regional: esta abordagem distribui o tráfego entre diferentes datacenters ou regiões geográficas. É utilizado para garantir que as solicitações de usuários sejam atendidas pelo datacenter mais próximo, minimizando a latência e melhorando a experiência do usuário. O balanceamento regional também proporciona resiliência ao distribuir a carga entre várias regiões, garantindo que, em caso de falha em uma região, outra possa assumir a carga.



Aplicações:

- **Aplicações Globais:** para empresas que atendem usuários espalhados por diferentes regiões do mundo, o balanceamento regional garante baixa latência e alta disponibilidade.
- **Redundância Geográfica:** em casos de desastre natural ou falha em um datacenter, o balanceamento regional pode redirecionar o tráfego para outras regiões sem interrupções significativas no serviço.

Balanceamento Interno: esta técnica é usada para distribuir o tráfego dentro de uma única região ou datacenter. É focada em otimizar a distribuição de carga entre servidores dentro de um ambiente mais localizado. O balanceamento interno é ideal para assegurar que nenhum servidor em um datacenter específico fique sobrecarregado, proporcionando alta disponibilidade e eficiência dentro de um ambiente controlado.

Aplicações:

- **Aplicações corporativas:** para organizações que operam dentro de um único datacenter ou região, o balanceamento interno ajuda a manter a eficiência operacional e a alta disponibilidade;
- **Redundância local:** garante que os serviços permaneçam disponíveis mesmo que um servidor falhe, redistribuindo a carga para outros servidores dentro do mesmo *datacenter*.

Escolha da solução correta:

- **Contexto geográfico:** se a aplicação precisa atender usuários distribuídos globalmente, o balanceamento regional é a melhor escolha. Se o foco é a eficiência dentro de um único datacenter, o balanceamento interno é mais adequado;
- **Requisitos de latência:** o balanceamento regional é ideal para minimizar a latência em aplicações globais, enquanto o balanceamento interno é suficiente para manter a latência baixa em ambientes locais;
- **Resiliência:** se a resiliência contra falhas regionais é crítica, o balanceamento regional deve ser implementado. Para garantir a continuidade dentro de uma única região, o balanceamento interno é mais relevante.



FINALIZANDO

O balanceamento de carga é um componente crucial na arquitetura de sistemas modernos, garantindo que aplicações e serviços sejam altamente disponíveis, escaláveis e seguros. Compreender os diferentes tipos de balanceadores de carga, como HTTP(S), SSL Proxy e TCP Proxy, permite às organizações escolher a solução mais adequada para suas necessidades específicas, seja na distribuição de tráfego web, no gerenciamento de conexões criptografadas ou na otimização de serviços de backend.

Ao decidir entre balanceamento regional e interno é essencial considerar o contexto geográfico, os requisitos de latência e as necessidades de resiliência da aplicação. O balanceamento regional oferece uma solução robusta para aplicações globais, assegurando baixa latência e redundância entre várias regiões, enquanto o balanceamento interno é ideal para otimizar a performance dentro de um datacenter ou região específica.

No geral, o uso estratégico dessas técnicas de balanceamento de carga contribui para uma infraestrutura mais eficiente, resiliente e capaz de suportar a crescente demanda por serviços confiáveis e de alta performance em um mundo cada vez mais conectado. Ao implementar as práticas corretas de balanceamento de carga, as empresas podem melhorar significativamente a experiência do usuário, reduzir o risco de falhas e maximizar a eficiência operacional.



REFERÊNCIAS

KUROSE, J. F.; ROSS, K. W. **Redes de computadores e a internet: uma abordagem top-down**. 6. ed. São Paulo: Pearson, 2013.

MODI, R. **Azure for architects: implementing cloud design, DevOps, IoT, and serverless solutions on your public cloud**. 2. ed. Birmingham: Packt Publishing, 2020.

MULLIGAN, J.; KRISHNAN, S.; YU, V. **Google Cloud Certified Professional Cloud Architect All-in-One Exam Guide**. 1. ed. New York: McGraw-Hill Education, 2020.

SCOTT, B. A. **AWS Certified Solutions Architect: Study Guide with Practice Questions and Labs: Associate SAA-C02 Exam**. 1. ed. Independently Published, 2021.

TANENBAUM, A. S.; WETHERALL, D. J. **Redes de computadores**. 5. ed. São Paulo: Pearson, 2011.